# 퇴근시간 버스승차인원 예측

□ 유원희

□ 황성현

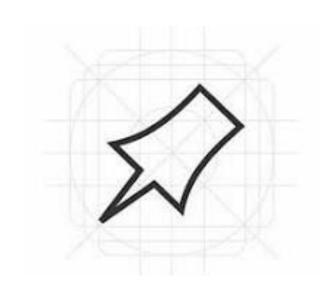
□ 김도현





# 목차

- 1. 주제 선정 배경
- 2. 목표
- 3. 데이터 수집 및 출처
- 4. 전처리
- 5. 모델링
- 6. 평가





## 주제 선정 배경



제주도내 주민등록인구는 2019년 11월 기준 69만명으로, 연평균 4%대로 성장했습니다. 외국인과 관광객까지 고려하면 전체 상주인구는 90만명을 넘을 것으로 추정됩니다. 제주도민 증가와 외국인의 증가로 현재 제주도의 교통체증이 심각한 문제로 떠오르고 있습니다. 2017년 한국은행 제주본부에 따르면 제주도 일부 지역은 교통체증이 서울보다 심각합니다. 따라서, 제주테크노파크는 교통난 심화를 해결하기 위해 데이터 분석 대회를 개최합니다.



# 목표

제주도 버스의 효율적인 운행를 위해 퇴근시간 승차인원을 예측하는 모델 개발









▶기존 대회 데이터(dacon 대회 데이터):train.csv, test.csv, bus\_bts.csv

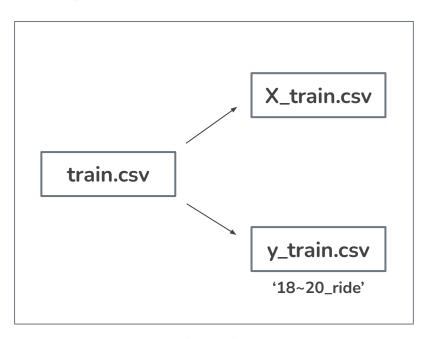
출처: https://dacon.io/competitions/official/229255/data

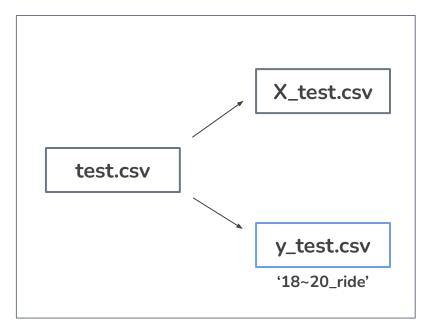
▶외부 데이터 : 2019년도 9~10월 기상정보 (기상자료개방포털)

출처: <a href="https://data.kma.go.kr/cmmn/main.do">https://data.kma.go.kr/cmmn/main.do</a>)



# Feature, Target 분리





9/1 ~ 9/30 10/1 ~ 10/16





#### □ 파생 변수 생성

- 1. route\_station = bus\_route\_id + station\_code
  - 특정 노선-정류소 조합에 대한 패턴을 더 쉽게 분석할 수 있다.(중요)
- 2. bus\_route\_id\_weekday = bus\_route\_id + weekday
  - 특정 요일에 대한 승하차 패턴을 분석
- 3. station\_code\_weekday = station\_code + weekday
  - 특정 정류소의 특정 요일에 발생하는 승하차 데이터를 고유하게 식별
- 4. route\_station\_weekday = route\_station + weekday
  - 특정 노선의 특정 정류소에서 특정 요일에 발생하는 패턴을 더 세밀하게 분석
- 5. on\_time
  - target이 18~20 으로 2시간 이므로 , 승 하차 시간대 통합 변수 생성 ( t ~ t+2)



#### bus\_route\_id + station\_code => route\_station

	bus_route_id	station_code
0	4270000	344
1	4270000	357
2	4270000	432
3	4270000	1579
4	4270000	1646
844	447	
415418	32820000	1129
415419	32820000	1564
415420	32820000	2322
415421	32820000	3291
415422	32820000	6115100

	route_station
0	4270000,344
1	4270000,357
2	4270000,432
3	4270000,1579
4	4270000,1646
***	
415418	32820000,1129
415418 415419	32820000,1129 32820000,1564
415419	32820000,1564
415419 415420	32820000,1564 32820000,2322 32820000,3291



## bus\_route\_id + weekday => bus\_route\_id\_weekday

weekday	bus_route_id	
6	4270000	0
6	4270000	1
6	4270000	2
6	4270000	3
6	4270000	4
0	32820000	415418
0	32820000	415419
0	32820000	415420
0	32820000	415421
0	32820000	415422

	bus_route_id_weekday
0	4270000,6
1	4270000,6
2	4270000,6
3	4270000,6
4	4270000,6
***	
415418	32820000,0
415419	32820000,0
415420	32820000,0
415421	32820000,0
415422	32820000,0



#### station\_code + weekday => station\_code\_weekday

	station_code	weekday
0	344	6
1	357	6
2	432	6
3	1579	6
4	1646	6
415418	1129	0
415419	1564	0
415420	2322	0
415421	3291	0
415422	6115100	0

	station_code_weekday
0	344,6
1	357,6
2	432,6
3	1579,6
4	1646,6
415418	1129,0
415419	1564,0
415420	2322,0
415421	3291,0
415422	6115100,0



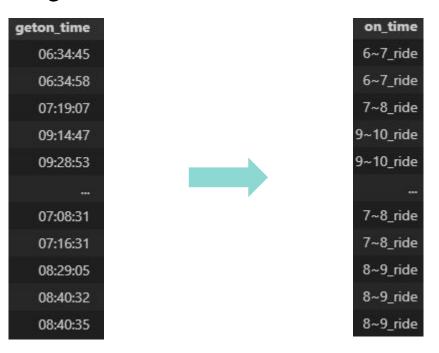
#### route\_station + weekday => route\_station\_weekday

	route_station	weekday
0	4270000,344	6
1	4270000,357	6
2	4270000,432	6
3	4270000,1579	6
4	4270000,1646	6
	s. <del></del>	
415418	32820000,1129	0
415419	32820000,1564	0
415420	32820000,2322	0
415421	32820000,3291	0
415422	32820000,6115100	0

ļ	route_station_weekday
0	4270000,344,6
1	4270000,357,6
2	4270000,432,6
3	4270000,1579,6
4	4270000,1646,6
1999	
415418	32820000,1129,0
415419	32820000,1564,0
415420	32820000,2322,0
415421	32820000,3291,0
415422	32820000,6115100,0

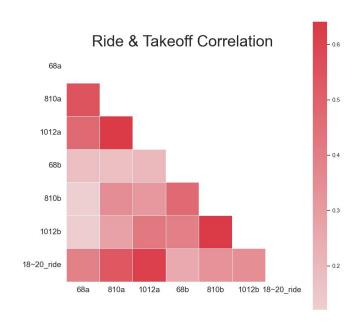


bts.csv 의 'geton\_time' 컬럼 시간대만 추출 => on\_time





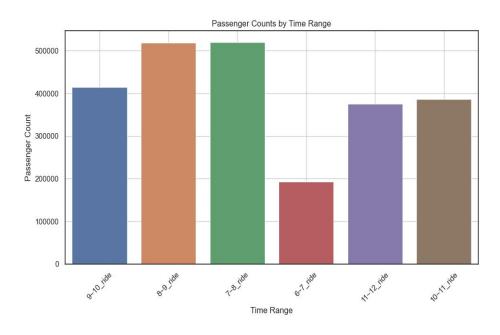
# 전처리 EDA



오전 8-10시, 10-12시의 승차인원이 18-20\_ride와 높은 상관관계를 보임



# EDA



12시 이전에는 7시부터9시 사이의 이용객이 많은 것을 확인



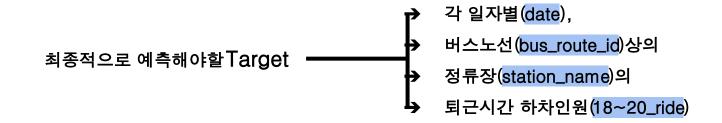
## EDA 후 파생 변수 생성

6~7_ride	7~8_ride	8~9_ride	9~10_ride	10~11_ride	11~12_ride
0.0	1.0	2.0	5.0	2.0	6.0
1.0	4.0	4.0	2.0	5.0	6.0
1.0	1.0	0.0	2.0	0.0	0.0
0.0	17.0	6.0	26.0	14.0	16.0
0.0	0.0	0.0	0.0	0.0	0.0
				***	
4.0	0.0	0.0	0.0	0.0	0.0
4.0	0.0	0.0	0.0	0.0	0.0
0.0	0.0	0.0	0.0	0.0	0.0
1.0	0.0	0.0	0.0	0.0	0.0
0.0	0.0	0.0	0.0	0.0	0.0

68a	810a	1012a
1.0	7.0	8.0
5.0	6.0	11.0
2.0	2.0	0.0
17.0	32.0	30.0
0.0	0.0	0.0
4.0	0.0	0.0
4.0	0.0	0.0
0.0	0.0	0.0
1.0	0.0	0.0
0.0	0.0	0.0

승 하차 시간대 2시간 간격 변수 생성







```
train, test = id_statistic('route_station', '1820_rs_mean', '1820_rs_sum')
train.shape, test.shape
```

```
train, test = id_statistic('bus_route_id', '1820_r_mean', '1820_r_sum')
train.shape, test.shape
```

```
train, test = id_statistic('station_code', '1820_s_mean', '1820_s_sum')
train.shape, test.shape
```

```
train, test = id_statistic('weekday', '1820_w_mean', '1820_w_sum')
train.shape, test.shape
```

1820_rs_sum	1820_rs_mean	1820_r_sum	1820_r_mean	1820_s_sum	1820_s_mean	1820_w_sum	1820_w_mean
44.0	1.466667	2409.0	3.104381	44.0	1.466667	54306.0	1.034282
161.0	5.366667	2409.0	3.104381	6330.0	4.178218	54306.0	1.034282
48.0	1.600000	2409.0	3.104381	1625.0	2.169559	54306.0	1.034282
1613.0	53.766667	2409.0	3.104381	1613.0	52.032258	54306.0	1.034282
4.0	0.153846	2409.0	3.104381	181.0	0.732794	54306.0	1.034282
0.0	0.000000	0.0	0.000000	1108.0	2.393089	104073.0	1.343710
0.0	0.000000	0.0	0.000000	5555.0	7.726008	104073.0	1.343710
0.0	0.000000	0.0	0.000000	59.0	0.320652	104073.0	1.343710
0.0	0.000000	0.0	0.000000	160.0	1.333333	104073.0	1.343710
0.0	0.000000	0.0	0.000000	83.0	0.188636	104073.0	1.343710

각 컬럼(route\_station, bus\_route\_id, station\_code, weekday)별 18~20\_ride(평균 값, 더한 값)의 파생 변수 생성



## bus\_route\_id => congestion(18~20\_ride 혼잡도)

```
def congestion():
  # 버스 노선별 총 승객 수 계산
  df = train.groupby(['bus_route_id'])['18~20_ride'].agg([('passenger', 'sum')]).reset_index()
  def get congestion level(passenger):
      if passenger > 10000:
      elif passenger > 5000:
          return 6
      elif passenger > 2000:
      elif passenger > 700:
      elif passenger > 200:
          return 3
      elif passenger > 50:
  df['congestion'] = df['passenger'].apply(get_congestion_level)
  df = df[['bus_route_id', 'congestion']]
  # 학습 데이터와 테스트 데이터에 혼잡도 정보 병합
  tr = pd.merge(train, df, how='left', on='bus route id')
  te = pd.merge(test, df, how='left', on='bus route id')
  te['congestion'] = te['congestion'].fillna(df['congestion'].median())
  return tr, te
```





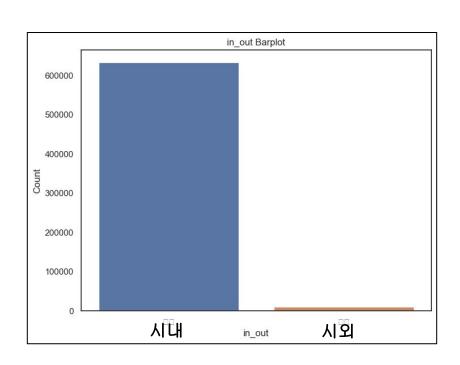
```
bts['geton_time2'] = pd.to_datetime(bts['geton_time'])

f = bts.groupby(['geton_date', 'geton_time2', 'geton_station_code', 'bus_route_id'])['user_count'].\
agg([('탑음객_수', 'sum')]).reset_index().\
sort_values(by=['geton_date', 'geton_station_code', 'bus_route_id', 'geton_time2'], ascending=True).reset_index()

f['index'] = list(range(0,len(f)))
```

배차 간격도 예측하는데 관련이 있을 거 같아 변수로 사용

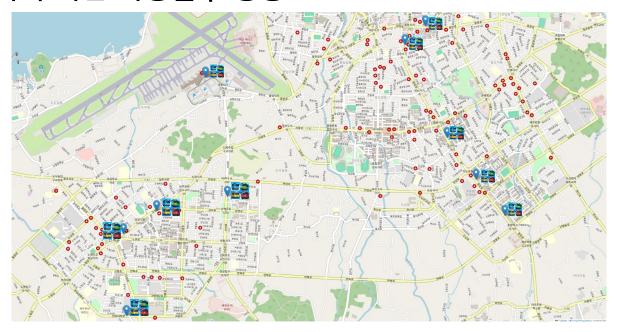




시내와 시외를 0 과 1로 변환



#### 거리에 따른 파생변수 생성



제주시와 주변 주요 지점과의 거리를 계산함으로써, 특정 버스 정류장이 얼마나 접근성이 좋은지 평가



#### 제주시와 주변 주요 지점과의 거리를 계산하여 변수 생성

```
coords jejusi = (33.500770, 126.522761) #제주시의 위도 경도
data['dis jejusi'] = [geodesic((data['latitude'].iloc[i], data['longitude'].iloc[i]), coords jejusi).km for i in range(len(data))]
coords jejusicheong1 = (33.49892, 126.53035) #제주시청(광양방면)의 위도 경도
coords_jejuairport = (33.50661, 126.49345) #제주국제공항(구제주방면)의 위도 경도
coords hallahosp = (33.48963, 126.486) #한라병원의 위도 경도
coords rotary = (33,49143, 126,49678) # 제주도청신제주로터리의 위도 경도
coords_jejucenterhigh = (33.48902, 126.5392) #제주중앙여자고등학교의 위도 경도
coords jejumarket = (33.51315, 126.52706) #동문시장의 위도 경도
coords jejusclass = (33.47626, 126.48141) #제주고등학교/중흥S클래스의 위도 경도
coords_centerroad = (33.51073, 126.5239) #중앙로(국민문행)의 위도 경도
coords_fiveway = (33.48667, 126.48092) # 노형오거리의 위도 경도
coords_law = (33.49363, 126.53476) # 제주지방법원(광양방면)의 위도 경도
data['dis_jejusicheong1'] = [geodesic((data['latitude'].iloc[i],data['longitude'].iloc[i]), coords_jejusicheong1).km for i in range(len(data))]
data['dis jejuairport'] = [geodesic((data['latitude'].iloc[i],data['longitude'].iloc[i]), coords jejuairport).km for i in range(len(data))]
data['dis_hallahosp'] = [geodesic((data['latitude'].iloc[i],data['longitude'].iloc[i]), coords_hallahosp).km for i in range(len(data))]
data['dis rotary'] = [geodesic((data['latitude'].iloc[i],data['longitude'].iloc[i]), coords rotary).km for i in range(len(data))]
data['dis_jejucenterhigh'] = [geodesic((data['latitude'].iloc[i],data['longitude'].iloc[i]), coords_jejucenterhigh).km for i in range(len(data))]
data['dis jejumarket'] = [geodesic((data['latitude'].iloc[i],data['longitude'].iloc[i]), coords jejumarket).km for i in range(len(data))]
data['dis_jejusclass'] = [geodesic((data['latitude'].iloc[i],data['longitude'].iloc[i]), coords_jejusclass).km for i in range(len(data))]
data['dis centerroad'] = [geodesic((data['latitude'].iloc[i],data['longitude'].iloc[i]), coords centerroad).km for i in range(len(data))]
data['dis_fiveway'] = [geodesic((data['latitude'].iloc[i],data['longitude'].iloc[i]), coords_fiveway).km for i in range(len(data))]
data['dis_law'] = [geodesic((data['latitude'].iloc[i],data['longitude'].iloc[i]), coords_law).km for i in range(len(data))]
data.shape
```



#### 출근 시간별 총 승객

```
data['ride_sum'] = data['6~7_ride'] + data['7~8_ride'] + data['8~9_ride'] + data['9~10_ride'] + data['10~11_ride'] + data['11~12_ride']

data['takeoff_sum'] = data['6~7_takeoff'] + data['7~8_takeoff'] + data['8~9_takeoff'] + data['9~10_takeoff'] + data['10~11_takeoff'] + data['11~12_takeoff']
```

#### 날짜 및 시간대별 총 승객

```
f = data.groupby('date')['6~7_ride'].agg([('6~7_all_ride_number', 'sum')]).reset_index()
data = pd.merge(data, f, how='left')

f = data.groupby('date')['7~8_ride'].agg([('7~8_all_ride_number', 'sum')]).reset_index()
data = pd.merge(data, f, how='left')

f = data.groupby('date')['8~9_ride'].agg([('8~9_all_ride_number', 'sum')]).reset_index()
data = pd.merge(data, f, how='left')

f = data.groupby('date')['9~10_ride'].agg([('9~10_all_ride_number', 'sum')]).reset_index()
data = pd.merge(data, f, how='left')

f = data.groupby('date')['10~11_ride'].agg([('10~11_all_ride_number', 'sum')]).reset_index()
data = pd.merge(data, f, how='left')
```



#### 요일 별 Target 평균 수 생성

```
def week_mean(data):
   # 데이터프레임 초기화
   df = data.reset index(drop=True)
   # 요일별 평균값 계산
   weekday_means = df.groupby('weekday')['18~20_ride'].mean()
   # 새로운 열 'weekdaymean' 추가 및 기본값 설정
   df['weekdaymean'] = 1
   # 요일별 평균값 할당
   for weekday, mean_value in weekday_means.items():
       df.loc[df['weekday'] == weekday, 'weekdaymean'] = mean value
   return df
```

	weekdaymean
0	1.034282
1	1.034282
2	1.034282
3	1.034282
4	1.034282
643588	1.430856
643589	1.430856
643590	1.430856
643591	1.430856
643592	1.430856



#### 각각의 측정소와 정류장 사이의 거리를 계산한 파생 변수 생성

```
def dist():
   jeju=(33.51411, 126.52969) # 제주 측정소 근처
   gosan=(33.29382, 126.16283) #고산 측정소 근처
   seongsan=(33.38677, 126.8802) #성산 측정소 근처
   po=(33.24616, 126.5653) #서귀포 측정소 근처
   t1 = [ (import) geodesic: Any m for i,j in list( zip( data['latitude'],data['longitude'] )) ]
   t2 = [geodesic((i,j), gosan).km for i,j in list(zip(data['latitude'],data['longitude']))]
   t3 = [geodesic( (i,j), seongsan).km for i,j in list( zip( data['latitude'],data['longitude'] )) ]
   t4 = [geodesic((i,j), po).km for i,j in list(zip(data['latitude'],data['longitude']))]
   data['dis jeju'] = t1
   data['dis gosan']=t2
   data['dis seongsan']=t3
   data['dis po']=t4
   total = pd.DataFrame(list(zip( t1,t2,t3,t4)),columns=['jeju','gosan','seongsan','po'])
   data['dist name'] = total.apply(lambda x: x.argmin(), axis=1)
    return data
```



비 오는 날과, 비 안오는 날 0과 1로 변환

```
# rainy_day
# 비 오는날=1, 비 안오는 날=0

def f(x):
    if x == 0:
       return 0
    else:
       return 1
```



#### 2개의 X 변수 데이터셋 생성

```
input_var1 = ['in_out','latitude','longitude','6-7_ride', '7-8_ride', '8-9_ride', '9-10_ride', '10-11_ride', '11-12_ride', '10-11_ride', '11-12_ride', '6-7_takeoff', '8-0_takeoff', '9-10_takeoff', '10-11_takeoff', '11-12_takeoff', '11-12_takeoff', '10-11_ride', '11-12_takeoff', '11-12_takeoff'
```

var1 var2



#### var1으로 LightGBM 학습 (GridSearchCV)

GridSearch로 하이퍼파라미터최적화 (var1)

```
import lightgbm as lgb
lgbm = lgb.LGBMRegressor()
param_grid = {
    'n_estimators': [500],
    'num leaves': [31, 50],
    'learning rate': [0.05],
    'min child samples': [20, 50],
    'max_depth': [-1, 10],
    'feature_fraction': [0.8, 1.0],
    'bagging_fraction': [0.8, 1.0],
    'lambda 11': [0, 0.1].
    'lambda_12': [0, 0.1],
    'boosting_type': ['dart'],
    'subsample': [0.8, 1.0],
    'colsample_bytree': [0.8, 1.0]
grid_search = GridSearchCV(estimator = lgbm, param_grid = param_grid, cv = 3, scoring = 'neg_mean_squared_error',
                          verbose = 1, n_jobs = -1)
grid_search.fit(X_train1[my_var1], y_train)
print("Best parameters : ", grid_search.best_params_)
best_model = grid_search.best_estimator_
X_test['18~20_ride'] = best_model.predict(X_test[my_var1])
X_test[['id','18~20_ride']].to_csv("lightgbm_gridCV_result.csv",index=False)
```



#### var1으로 LightGBM 학습 (GridSearchCV)

GridSearch로 하이퍼파라미터최적화 (var1)

```
import lightgbm as lgb
lgbm = lgb.LGBMRegressor()
param_grid = {
    'n estimators': [500],
    'num leaves': [31, 50],
    'learning rate': [0.05],
    'min child samples': [20, 50],
    'max_depth': [-1, 10],
    'feature fraction': [0.8, 1.0],
    'bagging_fraction': [0.8, 1.0],
    'lambda 11': [0, 0.1].
    'lambda_12': [0, 0.1],
    'boosting_type': ['dart'],
    'subsample': [0.8, 1.0],
    'colsample bytree': [0.8, 1.0]
grid_search = GridSearchCV(estimator = lgbm, param_grid = param_grid, cv = 3, scoring = 'neg_mean_squared_error',
                          verbose = 1, n jobs = -1)
grid_search.fit(X_train1[my_var1], y_train)
print("Best parameters : ", grid_search.best_params_)
best_model = grid_search.best_estimator_
X_test['18~20_ride'] = best_model.predict(X_test[my_var1])
X_test[['id','18~20_ride']].to_csv("lightgbm_gridCV_result.csv",index=False)
```

RMSE: 2.2461403605



#### var2으로 LightGBM 학습 (GridSearchCV)



#### var2으로 LightGBM 학습 (GridSearchCV)

RMSE: 2.2268666474



#### var2으로 LightGBM 학습 (GridSearchCV)

RMSE: 2.2268666474

1

1차 모델링 최저 RMSE



LightGBM 의 feature selection

for i in range(len(feature\_importance)):

mean rmse = np.mean(scores)

rmse\_list.append(mean\_rmse)
features\_list.append(selected\_features)
print(f"Removed {i} features, Mean\_RMSE: {mean\_rmse}")

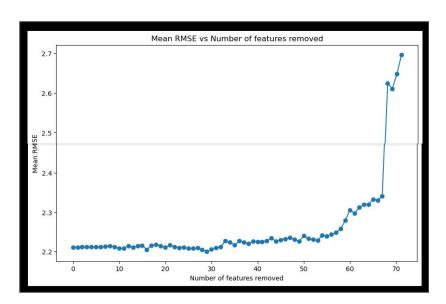
# 회적의 특성 조합 찾기 min\_rmse\_index = np.argmin(rmse\_list) best\_features = features\_list[min\_rmse\_index] best\_rmse = rmse\_list[min\_rmse\_index]

selected\_features = feature\_importance['feature'][i:].tolist()
X\_train\_selected = X\_train1[selected\_features]
# 교자 점점을 사용하여 모일 성능 증가

print(f"\nBest Mean RMSE: {best\_rmse} with features: {best\_features}")

scores = cross\_val\_score(model, X\_train\_selected, y\_train1, cv=5, scoring=rmse\_scorer)

#### LightGBM으로 var1에 대해 Feature Selection





#### Feature Selection으로 best\_var1, best\_var2 생성

#### var1 => best var1

#### var2 => best\_var2

```
input_var3 = ['sum_avg_spend', '68a', '810a', 'si_제주시', 'dong2', 'bus_interval', 'dis_jejuairport', 'ride_sum',
             'takeoff sum', '1820 rs mean', '1820 rs sum', '1820 r mean', '1820 r sum', '1820 s mean',
             '1820_s_sum','congestion', 'bus_route_id2', '6~7_all_ride_number', '7~8_all_ride_number',
             '8~9 all ride number', '1012a mean', '1012b sum', '10~11 ride sum', '10~11 takeoff sum', '11~12 ride sum',
             '11~12 takeoff sum', '1820 r mean sum', '1820 r mean mean',
             '1820 r sum sum', '1820 r sum mean', '1820 rs mean sum',
             '1820 s mean sum', '1820 s mean mean', '1820 s sum sum',
             '1820 s sum mean', '1820 w mean sum', '1820 w mean mean',
             '1820 w_sum_mean', '68a_sum', '68a_mean', '68b_sum', 'in_out', 'latitude', 'longitude',
             '6~7 ride', '7~8 ride', '8~9 ride', '9~10 ride', '10~11 ride', '11~12 ride', '6~7 takeoff', '7~8 takeoff',
             '8~9 takeoff', '9~10 takeoff', '10~11 takeoff', '11~12 takeoff',
             'weekday 5', 'weekday 6', 'dis jejusi', '68b mean', '6~7 ride sum',
             '6~7 ride mean', '6~7 takeoff sum', '6~7 takeoff mean', '7~8 ride sum',
             '7~8 ride mean', '7~8 takeoff sum', '7~8 takeoff mean', '810a sum',
             '810b sum', '8~9 ride sum', '8~9 takeoff sum', '8~9 takeoff mean',
             '9~10 ride sum', '9~10 takeoff sum', 'route station weekday2']
```

\*var2는 Feature Selection 후 오히려 RMSE가 증가하여 var2 = best\_var2로 설정함



4개의 모델 생성 후 best\_var1, best\_var2 학습

best\_var1 LightGBM(GridSearchCV)

best\_var1 RandomForest(GridSearchCV)

best\_var2 LightGBM(GridSearchCV)

best\_var2 RandomForest(GridSearchCV)



4개의 모델 생성 후 best\_var1, best\_var2 학습

best_var1	$\rightarrow$	LightGBM(GridSearchCV)	$\rightarrow$	2.2178664654
best_var1	$\rightarrow$	RandomForest(GridSearchCV)	$\rightarrow$	2.2974108683
best_var2	$\rightarrow$	LightGBM(GridSearchCV)	$\rightarrow$	2.227398048
best_var2	<b></b>	RandomForest(GridSearchCV)	$\rightarrow$	2.2008937695



4개의 모델 생성 후 best\_var1, best\_var2 학습

LightGBM(GridSearchCV) best\_var1 2.2178664654 RandomForest(GridSearchCV) 2.2974108683 best\_var1 LightGBM(GridSearchCV) best\_var2 2.227398048 RandomForest(GridSearchCV) best\_var2 2.2008937695

> ■ 2차 모델링 최저 RMSE



#### 4개 모델의 Optuna 하이퍼파라미터최적화

```
The state of the s
```

```
LightGBM_best_var1
+
Optuna
```

```
| Section | Sect
```

LightGBM\_best\_var2 + Optuna

```
The state of the s
```

RandomForest\_best\_var1 + Optuna

```
The state of the s
```

RandomForest\_best\_var2
+
Optuna

8개의 모델 생성 후 A, B, C, D 생성

best\_var1 \_\_\_ LightGBM(GridSearchCV)
LightGBM(Optuna) LightGBM(GridSearchCV)
LightGBM(Optuna) 



8개의 모델 생성 후 A, B, C, D 생성

best_var1	$\overline{}$	LightGBM(GridSearchCV) LightGBM(Optuna)	<b>→</b>	A
best_var1	$\overline{}$	LightGBM(GridSearchCV) LightGBM(Optuna)	<b>→</b>	В
best_var2	$\overline{}$	RandomForest(GridSearchCV) RandomForest(Optuna)	<b></b>	С
best_var2	$\overline{}$	RandomForest(GridSearchCV) RandomForest(Optuna)	<b></b>	D



A =2.2178664654

RMSE가 가장 낮은 조합 찾기

1개 조합: (A, B, C, D) >> 4개

2개 조합: (A+B, A+C, A+D, B+C, B+D, C+D) / 2 >> 6개

3개 조합: (A+B+C, A+B+D, B+C+D, A+C+D) / 3 >> 4개

4개 조합: (A+B+C+D) / 4 >> 1개

A + B = 2.2417782747

$$A + B + C = 2.2256394242$$
  $A + B + C + D = 2.2088098707$   $A + B + D = 2.2124034029$   $B + C + D = 2.2125531226$   $A + C + D = 2.1967870071$ 



A =2.2178664654

RMSE가 가장 낮은 조합 찾기

1개 조합: (A, B, C, D) >> 4개

2개 조합: (A+B, A+C, A+D, B+C, B+D, C+D) / 2 >> 6개

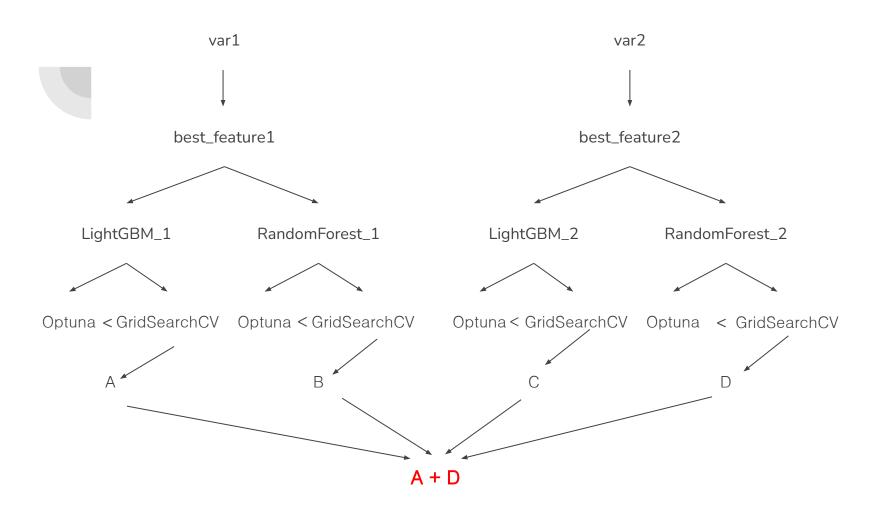
3개 조합: (A+B+C, A+B+D, B+C+D, A+C+D) / 3 >> 4개

4개 조합: (A+B+C+D) / 4 >> 1개

A + B = 2.2417782747

$$A + B + C = 2.2256394242$$
  $A + B + C + D = 2.2088098707$   $A + B + D = 2.2124034029$   $B + C + D = 2.2125531226$   $A + C + D = 2.1967870071$ 





# 결과

1	i7_돌하르방	<b>(a)</b>	2.15681	38	
2	Dining		2.1609	68	
3	TEAM-EDA	s P P Ta	2.16185	27	
4	STATION	Sp	2.16739	3	
5	임진혁(JinSloth)	6	2.17037	6	
6	KIMCHAJANG	<b>€ € € €</b>	2.17543	33	
7	sayho	ja	2.17899	2	
8	GGg123	<b>60</b>	2.18337	15	
9	내가일등할거다	90	2.1917	70	120
10	unun	m	2.1933	11	
11	우리팀 ^^		2.19348		
11	LEE91	<b>®</b>	2.19658	6	ANI/A



